Traducción de campo claro a fase plausible en eritrocitos con CycleGAN: evaluación de viabilidad con pérdidas físicas y morfológicas

Jacobo Giraldo · Juan Lotero · Sahian Salome

Proyecto DL-QPI, aprendizaje profundo · 12 de noviembre de 2026

Resumen. Se estudió si un CycleGAN no pareado [1] puede convertir parches de campo claro de frotis de *P. vivax* en mapas de fase plausibles como los de microscopía holográfica digital (DHM) del dataset de Castañeda, Trujillo y Doblas [4]. El trabajo se hizo en siete notebooks: ingesta, dos EDA, limpieza y armonización de los dos dominios, una heurística de validación por segmentación y perfil de fase, máscaras SAM por célula y el desarrollo del modelo. Al CycleGAN se le agregaron un término físico sobre el delta de fase máximo-mínimo ($\Delta\varphi$) de cada eritrocito y, tras varios intentos fallidos documentados aquí, una pérdida morfológica con las máscaras del campo claro. Sin esta última, el generador ubicaba las células donde la entrada tenía fondo o invertía la polaridad de la fase, y aun así reconstruía el ciclo. La solución final (`cyclegan_ep10_lphys10_filtrado_morph2`, 10 épocas) conserva la posición y la forma de las células desde la primera época (IoU 0.67–0.76), baja el KID de 0.24 a 0.060 y da una mediana de $\Delta\varphi$ de 1.98 rad frente a 1.63 rad de la fase real, con una distribución más concentrada que la real.

1. Problema, objetivos y trabajos relacionados

La DHM mide el retardo de fase que un eritrocito impone a la luz, una magnitud cuantitativa ligada a su espesor y a su índice de refracción. Los datasets de DHM son de células sanas; los de malaria son de campo claro. El objetivo general fue evaluar la viabilidad de generar fase plausible a partir de campo claro con un CycleGAN no pareado, conservando la morfología de las células de entrada y reproduciendo las estadísticas y los perfiles de fase de las imágenes DHM reales. Los objetivos específicos fueron:

(1) construir un dataset armonizado de los dos dominios;

(2) implementar un CycleGAN convencional y una variante con una pérdida orientada a la morfología y los perfiles de fase, con una heurística de segmentación para extraer perfiles y $\Delta\varphi$; y

(3) evaluar la plausibilidad con métricas de distribución, de conservación morfológica y de perfiles.

CycleGAN [1] aprende dos traducciones G_{AB} y G_{BA} entre dominios no pareados con pérdidas adversariales y de consistencia de ciclo; de él se toman la arquitectura (generador ResNet y discriminador PatchGAN), la pérdida LSGAN, $\lambda_{\text{ciclo}} = 10$ y el calendario de la tasa de aprendizaje. **PhaseGAN** [3] usa la misma idea para recuperar fase con datos no pareados y mete la física de formación de imagen dentro del ciclo (un modelo de propagación) más una pérdida en Fourier: muestra que el ciclo solo no basta y que conviene restringirlo con conocimiento físico. Aquí no existe un modelo directo de campo claro a fase, así que la física entra como una restricción sobre una estadística de la fase generada ($\Delta\varphi$). **TIE-GAN** [2] obtiene fase cuantitativa a partir de una sola imagen de intensidad con una GAN entrenada con pares generados por la ecuación de transporte de intensidad; confirma que la intensidad contiene información de fase aprovechable, pero depende de datos pareados, que en este problema no existen.

2. Datos y armonización (notebooks 00 a 04)

Fuentes. Fase: 36 864 pares holograma/fase de 256 × 256 de eritrocitos sanos, objetivo 40×/0.65 NA, píxel efectivo ≈ 0.15 µm [4]. Campo claro: 1 328 imágenes RGB de frotis de *P. vivax* (Kaggle) [5], de dos cámaras (1 208 de 1600 × 1200 y 120 de 1944 × 1383), con 86 035 cajas anotadas: 97.1 % eritrocitos sanos, 2.9 % infectados (trofozoíto, anillo, esquizonte, gametocito), más leucocitos y cajas «difficult». Los notebooks 00 a 02 cachean ambos zips en Drive, los descomprimen en el disco local de Colab y describen tamaños, canales, histogramas y anotaciones.

Campo claro (nb03). Se midió el tamaño de las células en fase segmentando 910 eritrocitos con Otsu: mediana de 51 px. El factor de escala por cámara es 51 px dividido por la mediana del tamaño de caja de los eritrocitos sanos de esa cámara: ×0.474 y ×0.374, con un CV entre imágenes de 0.077 y 0.049. Se eligió un factor fijo por cámara y no uno por imagen para conservar la variación real de tamaño, que es parte de lo que se quiere preservar. Luego se cortan parches de 256 × 256 con paso 128 y se descarta cada parche que toca una célula infectada (34.6 %), un leucocito o una caja «difficult» (7.0 %), que tiene menos de 3 células (3.2 %) o que tiene cúmulos (7.6 %). Quedan 12 616 de 26 560 parches (47.5 %), divididos 80/20 *por imagen de origen* y estratificados por cámara: 10 099 de entrenamiento y 2 517 de validación, con una mediana de 9

células por parche. La aumentación (las 8 simetrías del cuadrado) se aplica al azar en el DataLoader y no en disco, para no inflar el dataset ni filtrar copias entre particiones.

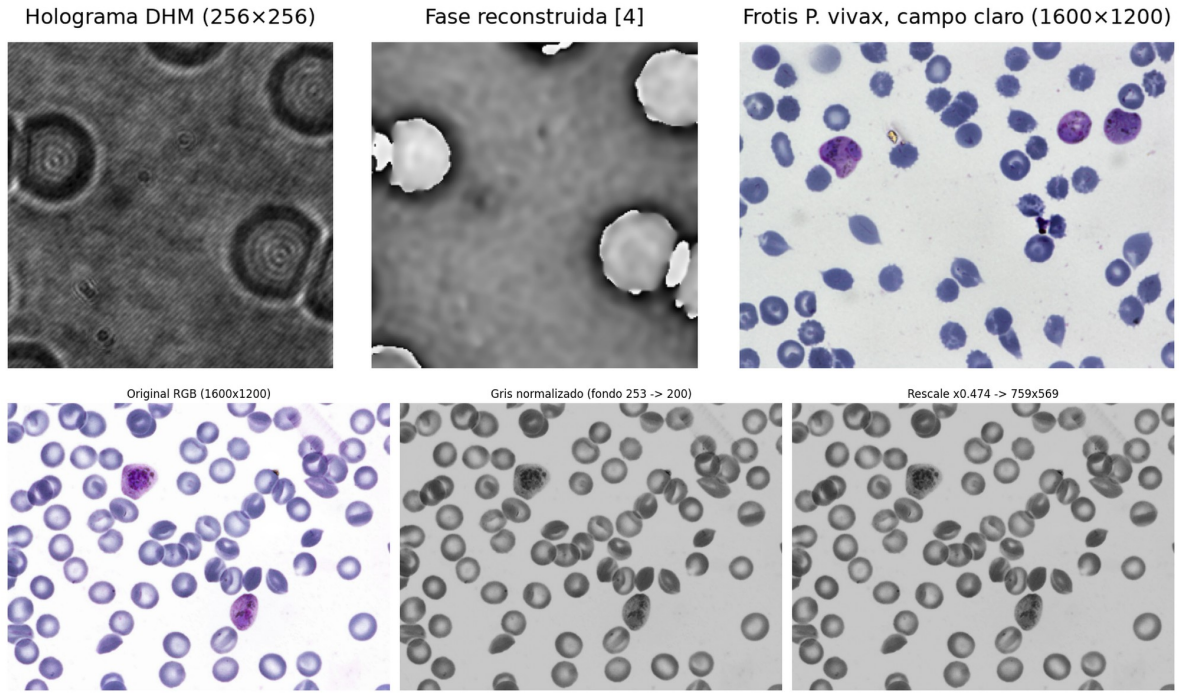


Figura 1. Arriba: par holograma/fase del dataset DHM [4] (nb01) y una imagen original de malaria (nb02). Abajo: pipeline de campo claro (nb03): RGB → gris (L de PIL) con el fondo llevado a un nivel fijo (253 → 200) → reescalado por cámara (×0.474) para que el eritrocito mida lo mismo que en fase.

Fase (nb04). El diagnóstico encontró cuatro problemas:

(i) cada recorte aparece tres veces, rotado o volteado (12 288 recortes únicos);

(ii) el split del paper tiene fuga: el 96 % de Validation está repetido en Training;

(iii) el 100 % de los PNG tiene mínimo 0 y máximo 255 exactos, es decir, están normalizados min-max por recorte, así que la fase queda en unidades relativas a cada recorte y no en radianes absolutos (se probó y se descartó la hipótesis de un desfase de fondo corregible en módulo 2π); y

(iv) muchos recortes tienen manchas oscuras por fase envuelta.

Se conservó una variante por recorte, se filtraron los recortes con artefactos con dos detectores complementarios y se hizo un split por holograma de origen: 2 292 recortes de entrenamiento (102 hologramas) y 442 de validación (27), con una mediana de 6 células por recorte. Los niveles de gris se mapean a $[-1, 1]$, el rango de la salida tanh, y la fase se interpreta como $\varphi = \pi \cdot x$.

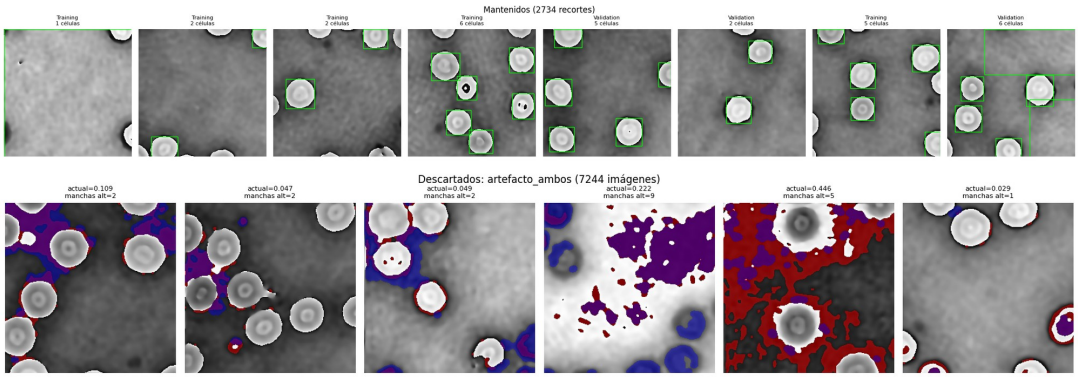


Figura 2. Limpieza de fase (nb04). Arriba: recortes mantenidos con las células segmentadas. Abajo: recortes descartados por artefactos de fase envuelta (en rojo, el detector de área oscura; en azul, el de manchas del tamaño de una célula).

3. Heurística de validación y máscaras por célula (nb05 y «mascaras sam»)

Para medir los perfiles sin aprendizaje se segmentan los eritrocitos de la fase con SAM ViT-B (generador automático de máscaras), con filtros de área, circularidad y contacto con el borde, y una supresión de máscaras duplicadas (la «barriguita» bicóncava salía como una segunda célula). Se toma el fondo como la mediana fuera de las células, se extrae el perfil a lo largo de la fila del centroide y se define

$$\Delta\varphi = \max - \min \quad \text{del perfil.}$$

Los píxeles con fase envuelta (0.7π por debajo de la mediana de la célula) se corrigen sumando 2π. En 8 imágenes reales, las 28 células interiores dieron una media de $\Delta\varphi$ de 2.02 ± 0.99 rad y una mediana de 1.90 rad, con el grueso entre 1.48 y 2.32. De ahí el equipo fijó el rango plausible $[1.4,\ 2.5]$ **rad**, una decisión arbitraria pero respaldada por esta distribución.

Para el campo claro se necesitan máscaras por célula, alineadas píxel a píxel con cada parche, para dos usos: el término físico y la pérdida morfológica. El notebook «mascaras sam» usa SamPredictor con las cajas anotadas como prompts (0.54 s por parche frente a 0.011 s de Otsu). Contra Otsu dentro de la caja, el IoU por célula es 0.86 en media y 0.94 en mediana ($n = 391$); se usó SAM porque da una máscara por caja aunque las células se toquen. Se generó un mapa de instancias `.npz` para los 12 616 parches.

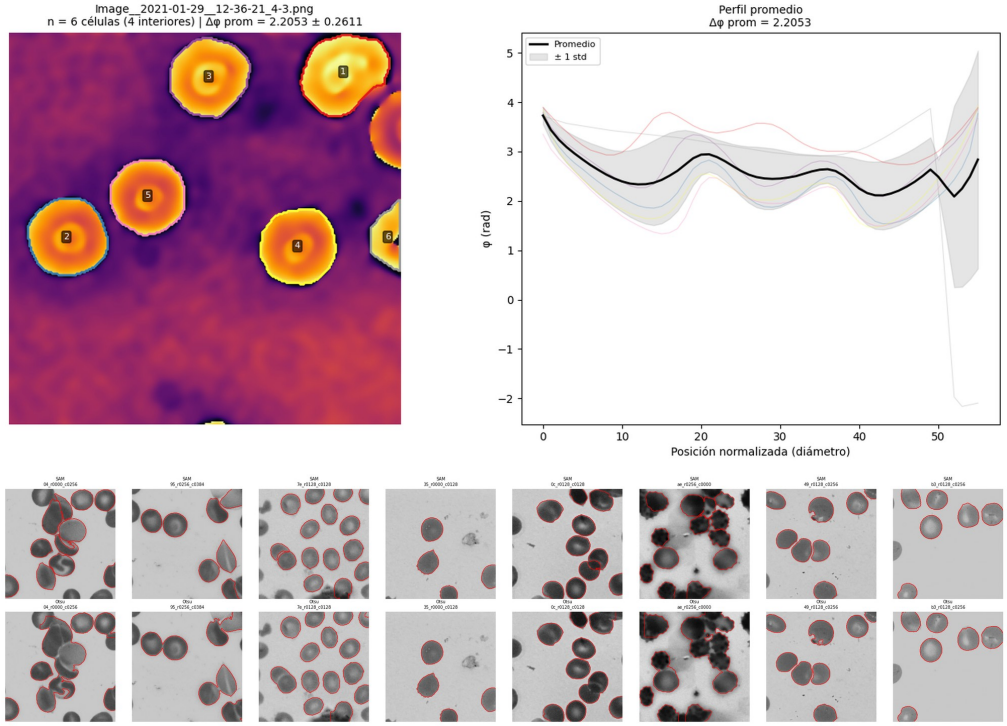


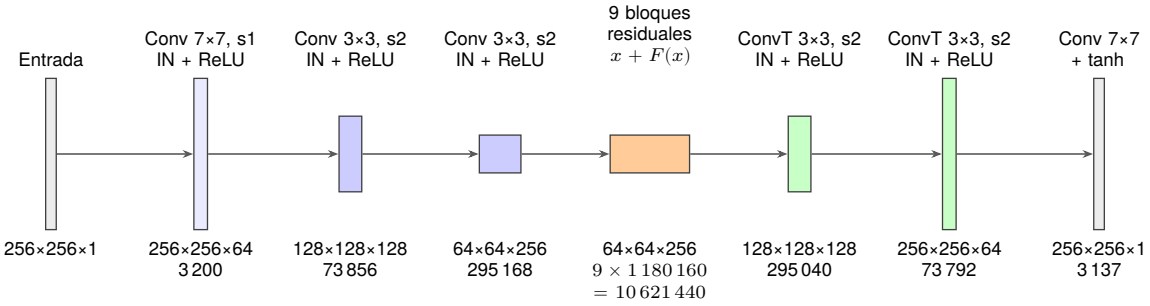
Figura 3. Arriba: heurística de nb05 sobre una fase real; células numeradas, perfiles por célula y perfil promedio ($\Delta\varphi$ medio 2.21 rad); la célula 6 toca el borde y se excluye. Abajo: máscaras de campo claro con SAM guiado por cajas (fila superior) frente a Otsu (fila inferior).

4. Modelo (nb06)

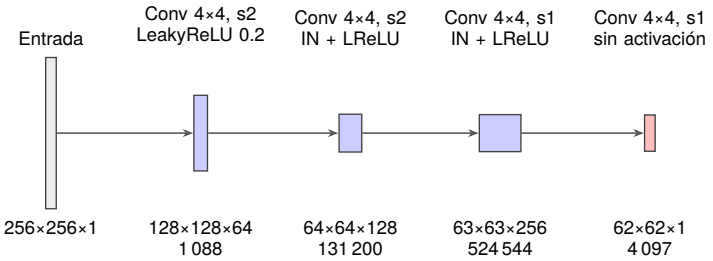
4.1 Arquitectura y parámetros entrenables

Se usan dos generadores ResNet-9 y dos discriminadores PatchGAN, como en [1], con una sola entrada y una sola salida de canal (gris o fase). El generador codifica a $64 \times 64 \times 256$ con dos convoluciones de paso 2, transforma con 9 bloques residuales y decodifica con dos convoluciones transpuestas hasta $256 \times 256 \times 1$ con tanh. Cada salida del generador ve $\approx 170 \times 170$ px de la entrada (campo receptivo), casi todo el parche. Esto le da capacidad para reubicar contenido, y explica por qué podía dibujar las células en otro sitio (sección 5). El discriminador tiene una capa menos que el PatchGAN 70×70 de [1]: produce un mapa de 62×62 puntajes, cada uno con un campo receptivo de 34×34 px, del orden de una célula.

Generador G_{AB} y G_{BA}: ResNet de 9 bloques, el de CycleGAN [1]. 11 365 633 parámetros entrenables cada uno



Discriminador D_A y D_B: PatchGAN de 4 capas. 660 929 parámetros entrenables cada uno



Salida: mapa de 62×62 puntajes; cada uno mira un parche de 34×34 px (campo receptivo) y se compara con 1 (real) o 0 (falso) por MSE (LSGAN).

$F(x)$ = Conv3×3-IN-ReLU-Conv3×3-IN, 256 canales.
IN: InstanceNorm sin parámetros afines.
Alto del bloque $\propto$ resolución; ancho $\propto$ canales.
Bajo cada bloque: salida (H×W×C) y parámetros.

Figura 4. Topología de capas, canales y mapas de características del generador y del discriminador (de `Generator` y `Discriminator` en nb06; parámetros contados con PyTorch).

Tabla 1. Parámetros entrenables. Todos los parámetros son pesos y sesgos de convoluciones.

Módulo	Parámetros	% del mód.	Comentario
G: conv. inicial 7×7 + 2 de bajada	372 224	3.3 %	Extraen bordes y textura; 7×7 con padding por reflexión
G: 9 bloques residuales (256 canales)	10 621 440	93.5 %	Casi toda la capacidad; cada bloque tiene 2 conv. 3×3 de 256 → 256 (590 k cada una)
G: 2 de subida + conv. final 7×7	371 969	3.3 %	ConvT 3×3 de paso 2; tanh a $[-1, 1]$
Generador (×2: G_{AB}, G_{BA})	11 365 633	100 %	Comparten un optimizador Adam
Discriminador (×2: D_A, D_B)	660 929	—	79 % en la tercera capa (128 → 256); uno por dominio
Total entrenable	**24 053 124**	—	Relación G:D ≈ 17:1. InstanceNorm sin parámetros afines (no suma)

4.2 Función de pérdida

Las pérdidas del generador son la adversarial LSGAN, la de ciclo, la física y la morfológica:

$$\mathcal{L}_{\text{adv}} = \mathbb{E}_a\big[(D_B(G_{AB}(a)) - 1)^2\big] + \mathbb{E}_b\big[(D_A(G_{BA}(b)) - 1)^2\big] \tag{1}$$

$$\mathcal{L}_{\text{ciclo}} = \mathbb{E}_a\big\|G_{BA}(G_{AB}(a)) - a\big\|_1 + \mathbb{E}_b\big\|G_{AB}(G_{BA}(b)) - b\big\|_1 \tag{2}$$

$$\Delta\varphi_i = \pi\Big(\max_{x \in r_i} G_{AB}(a)_x - \min_{x \in r_i} G_{AB}(a)_x\Big) \tag{3}$$

$$\mathcal{L}_{\Delta\varphi} = h(\overline{\Delta\varphi}), \qquad h(d) = \text{ReLU}(1.4 - d)^2 + \text{ReLU}(d - 2.5)^2 \tag{4}$$

$$\mathcal{L}_{\text{morf}} = \text{BCE}\left(\sigma\Big(\frac{G_{AB}(a) - t}{\tau}\Big),\ M_A\right) \tag{5}$$

$$\mathcal{L}_G = \mathcal{L}_{\text{adv}} + \lambda_{\text{ciclo}}\mathcal{L}_{\text{ciclo}} + \lambda_{\text{morf}}\mathcal{L}_{\text{morf}} + \lambda_{\text{fís}}\mathcal{L}_{\Delta\varphi}, \qquad \lambda_{\text{ciclo}} = 10,\quad \lambda_{\text{morf}} = 2,\quad \lambda_{\text{fís}} = 10 \tag{6}$$

En (3), r_i es la parte de la fila del centroide que cae dentro de la célula i (solo células que no tocan el borde) y la bisagra cuadrática h no castiga dentro de $[1.4, 2.5]$ rad. Hay dos modos: «lote», que aplica h al $\Delta\varphi$ medio del lote, y «célula», que aplica h a cada célula y promedia. En (5), M_A es la unión de las máscaras SAM de A, incluidas las cortadas por el borde; t es la mediana del umbral de Otsu de 200 fases reales de entrenamiento, con el mismo suavizado de la validación, y $\tau = 0.1$ fija el ancho de la sigmoide. Esta BCE castiga a la vez las

células dibujadas donde A tiene fondo y las células de A que quedan como fondo, así que fija la posición, la forma y la polaridad.

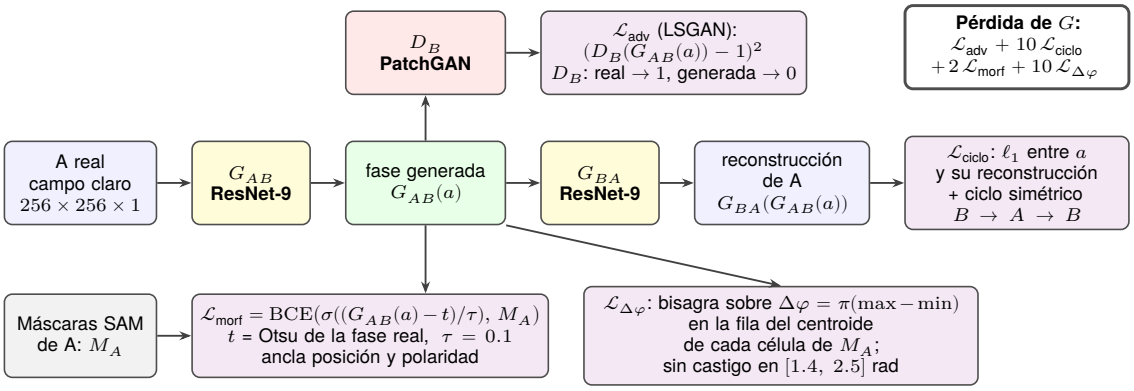


Figura 5. Esquema de entrenamiento: las pérdidas morfológica y física se aplican solo en $A \to B$, sobre la fase generada, con las máscaras SAM del parche de campo claro. El ciclo $B \to A \to B$ y el discriminador D_A son simétricos y no se dibujan.

Entrenamiento. Adam con $\mathrm{lr} = 2 \cdot 10^{-4}$ y $\beta = (0.5,\ 0.999)$; tasa constante la primera mitad y decaimiento lineal en la segunda [1]; lotes de 4; precisión mixta (bf16 en GPU Ampere); aumentación diédrica con la misma simetría para el parche y su máscara. Desde el intento 3 se usa un **filtro de densidad**: solo entran los parches A con ≤ 8 células y sin células en contacto (a 2 px). Quedan 3 779 de entrenamiento y 960 de validación, porque la fase real tiene una mediana de 7 componentes por parche y células separadas, frente a 9 células, a menudo pegadas, en campo claro.

4.3 Validación por época

Al final de cada época se generan las fases de las 960 imágenes de validación de A y se calculan cuatro métricas:

(i) **KID** (Kernel Inception Distance, subconjuntos de 200) entre la fase generada y las 442 fases reales: mide similitud de distribuciones y se compara entre corridas, no como valor absoluto, porque la Inception es de ImageNet.

(ii) **IoU** entre el primer plano de Otsu de la fase generada y la unión de las máscaras de A: mide la conservación morfológica y es ≈ 0 si la polaridad se invierte.

(iii) $\Delta\varphi$ **por Otsu** sobre las células interiores, con los criterios de forma de nb05 y la reparación de wrap, aplicado igual a la fase generada y a la real: mediana, fracción en $[1.4, 2.5]$ y distancia de Wasserstein-1 (W1) a la distribución real. La referencia real es una mediana de 1.63 rad, un 60.5 % en rango y 1 419 células.

(iv) Se guardan los pesos de G_{AB} de cada época, y dos celdas de inspección grafican los perfiles generados contra los reales y el ciclo $B \to A \to B$.

5. Intentos y decisiones (corridas en Drive: `dl-qpi/runs`)

Tabla 2. Corridas documentadas, con las métricas de validación de la última época (del `history.json` de cada carpeta). Fase real: $\Delta\varphi$ mediana 1.63 rad, 60.5 % en rango.

#	Corrida (carpeta)	Cambio respecto al anterior	Ép.	KID	IoU	$\Delta\varphi$ med.	% rango	W1
1	`cyclegan`	Baseline sin término físico ni filtro	20	—	—	—	—	—
2	`cyclegan_ep10_lphys1`	+ $\mathcal{L}_{\Delta\varphi}$ por lote, $\lambda = 1$	10	0.088	0.45	2.41	57.5	0.76
3a	`…_ep10_lphys10_celula_filtrado`	+ filtro; $\mathcal{L}_{\Delta\varphi}$ por célula, $\lambda = 10$	10	0.319	0.01	2.24	33.3	0.85
3b	`…_ep10_lphys1_filtrado`	Filtro; por lote, $\lambda = 1$	10	0.037	0.56	2.06	66.7	0.33
3c	`…_ep20_lphys1_filtrado`	Igual que 3b, 20 épocas	20	0.038	0.56	2.05	69.1	0.36
4a	`…_ep10_lphys1_filtrado_inv`	Campo claro negado ($A \to -A$)	10	0.184	0.01	1.68	71.0	0.12
4b	`…_ep10_lphys10_filtrado_inv`	Negado, $\lambda = 10$ por lote	10	0.317	0.01	1.31	32.9	0.42
4c	`…_ep20_lphys10_filtrado_inv`*	Negado, $\lambda = 10$, 20 épocas	20	0.130	0.01	1.35	40.5	0.27
5	`…_ep10_lphys10_filtrado_morph2`	+ $\mathcal{L}_{morf}$, $\lambda = 2$ (sin negar A)	10	**0.060**	**0.71**	**1.98**	**86.4**	**0.32**

* Carpeta ya no presente en Drive; valores de la salida del notebook.
La corrida `…_ep10_lphys1_celula_filtrado` se interrumpió sin historial.

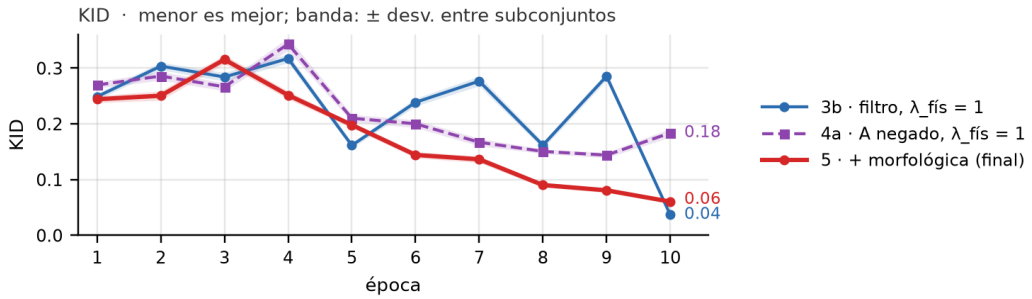


Figura 6. KID de validación por época en tres corridas de 10 épocas: 3b (filtro, las mejores métricas sin pérdida morfológica), 4a (igual a 3b, pero con A negado) y 5 (final). 3b oscila entre 0.16 y 0.32 y solo en la última época llega a 0.037; 5 baja de forma casi monótona desde la época 3 hasta 0.060.

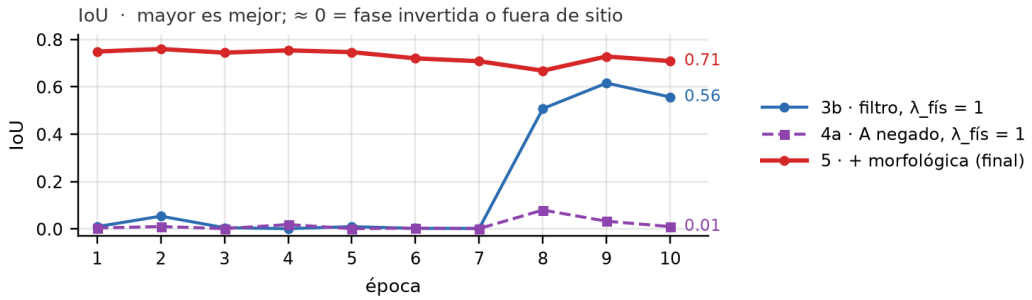


Figura 7. IoU entre el primer plano de Otsu de $G_{AB}(A)$ y las máscaras de A, en las mismas corridas. IoU ≈ 0 marca las épocas con la fase invertida o fuera de sitio: 3b se endereza en la época 8 y 4a nunca. Con la pérdida morfológica (5), el IoU está entre 0.67 y 0.76 desde la primera época.

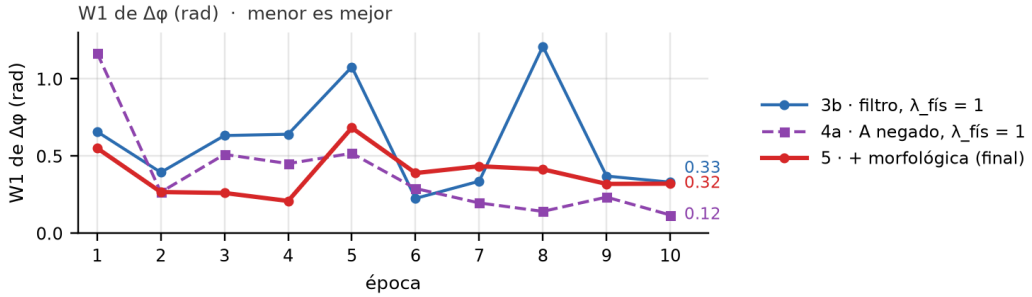


Figura 8. W1 entre las distribuciones de $\Delta\varphi$ por célula de la fase generada y la real (rad). Por sí sola no detecta el fallo: 4a termina con el menor W1 (0.12) aunque sus células están fuera de sitio (IoU 0.01), porque $\Delta\varphi$ se mide sobre la segmentación de la propia fase generada y no ve el signo ni la posición. Por eso se lee junto con el IoU.

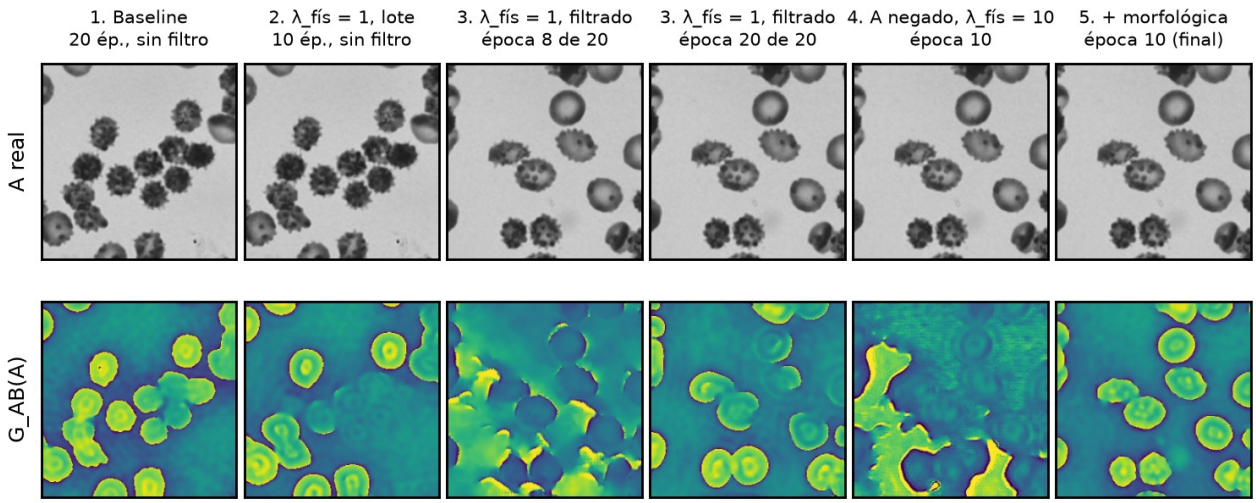


Figura 9. El mismo parche de validación (o el primero de cada corrida, pues 1 y 2 no usan el filtro) traducido por cada intento. En 3, época 8, y en 4 la fase sale invertida o desplazada; con la pérdida morfológica (5) cada célula queda en su sitio.

Intento 1 (baseline). Las células aisladas salen con un perfil plausible, pero las que se tocan se borran o se funden (fig. 9, primera columna), y aun así el ciclo A se reconstruye. El generador esconde la información en variaciones casi invisibles («esteganografía» de CycleGAN), porque el discriminador de fase nunca vio células pegadas.

Intento 2 (término físico por lote). $\mathcal{L}_{\Delta\varphi}$ quedó inerte: valía ≈ 0.01 frente a ≈ 1–2 del ciclo ponderado, porque la media del lote ya caía en el rango aunque cada célula no. Además, $\Delta\varphi = \max - \min$ no ve el signo, así que una fase invertida también cumple el rango. *Decisión:* agregar el modo «célula» y el filtro de densidad, para que la densidad del campo claro se parezca a la de la fase.

Intento 3 (filtro). El filtro mejoró el KID (0.037–0.038), pero en 3b y 3c la fase sale invertida hasta las épocas 7 y 17 (IoU ≈ 0). En 3c solo se endereza en la época 18, y la orientación que se alcanza depende del arranque. Con $\lambda = 10$ por célula (3a), el término domina y el modelo no converge en 10 épocas.

Intento 4 (negar la entrada). Como el campo claro tiene células oscuras sobre fondo claro y la fase al revés, se probó $A \to -A$ para darle al generador la polaridad correcta de arranque, con una métrica nueva de polaridad. Falló en tres corridas: en ninguna época pasó del 8 % de parches con la polaridad correcta (0 % en la última), y las células aparecen donde A tiene fondo. El problema no era el signo de la entrada: ningún término ligaba la posición de las células de A con la de B. La consistencia de ciclo restringe el viaje de ida y vuelta, no la imagen intermedia. También se consideró la pérdida de identidad de [1], pero se descartó porque solo restringe a G_{AB} sobre fases reales, no sobre campo claro.

6. Solución final: pérdida morfológica (corrida 5)

Configuración: filtro de densidad, sin negar A, $\lambda_{\text{ciclo}} = 10$, $\lambda_{\text{morf}} = 2$, $\lambda_{\text{fís}} = 10$ por lote, 10 épocas (24 min en GPU), t calculado sobre la fase real. A diferencia de todos los intentos anteriores, el IoU está entre 0.67 y 0.76 *desde la primera época*, y el KID baja de forma casi monótona de 0.32 (época 3) a 0.060. La curva de $\mathcal{L}_{\text{morf}}$ baja de 0.41 a 0.25, mientras el ciclo sigue bajando (0.26 → 0.09): la restricción espacial no impidió reconstruir.

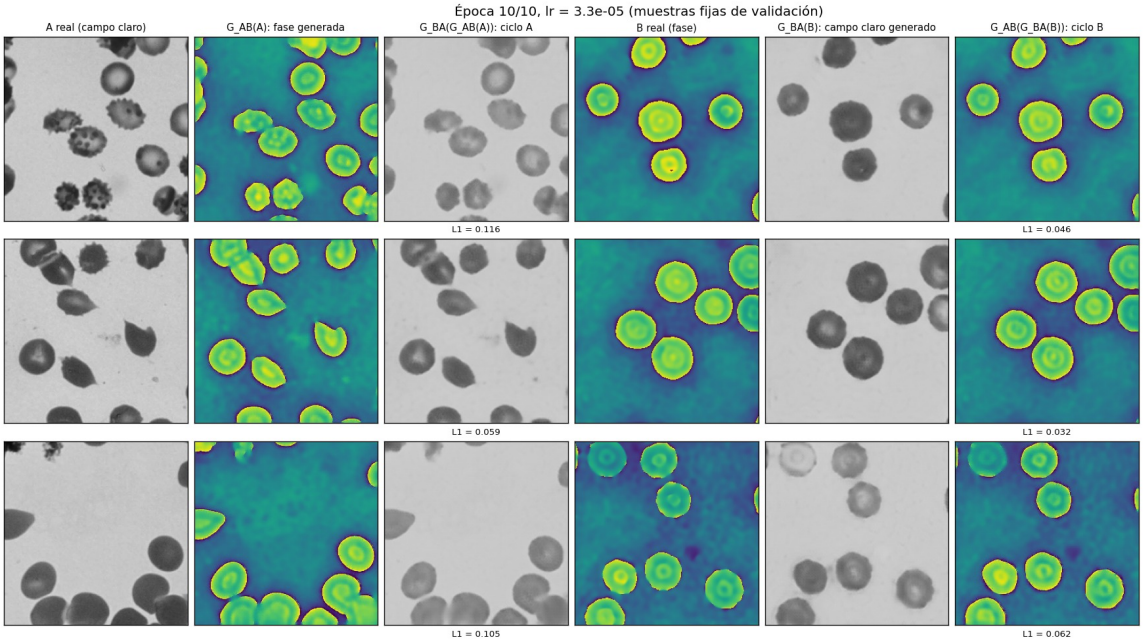


Figura 10. Corrida final, época 10, muestras fijas de validación. De izquierda a derecha: A real, fase generada $G_{AB}(A)$, ciclo A, B real, campo claro generado $G_{BA}(B)$ y ciclo B. Las células conservan posición, contorno (incluidos equinocitos y células elongadas) y polaridad, y muestran el anillo y la depresión central de la fase real.

7. Limitaciones

- **Fase en unidades relativas.** Los PNG del dataset están normalizados min-max por recorte, así que $\Delta\varphi$ es plausible respecto a este dataset, no en radianes físicos comparables con una medición DHM.
- **Métricas.** Con $\mathcal{L}_{\text{morf}}$ el IoU deja de ser independiente. Las métricas que quedan son el KID (con features de ImageNet, solo comparativo), la distribución de $\Delta\varphi$ y los perfiles. La fracción en rango del 86 % frente al 60 % real muestra que la distribución de $\Delta\varphi$ se comprime.

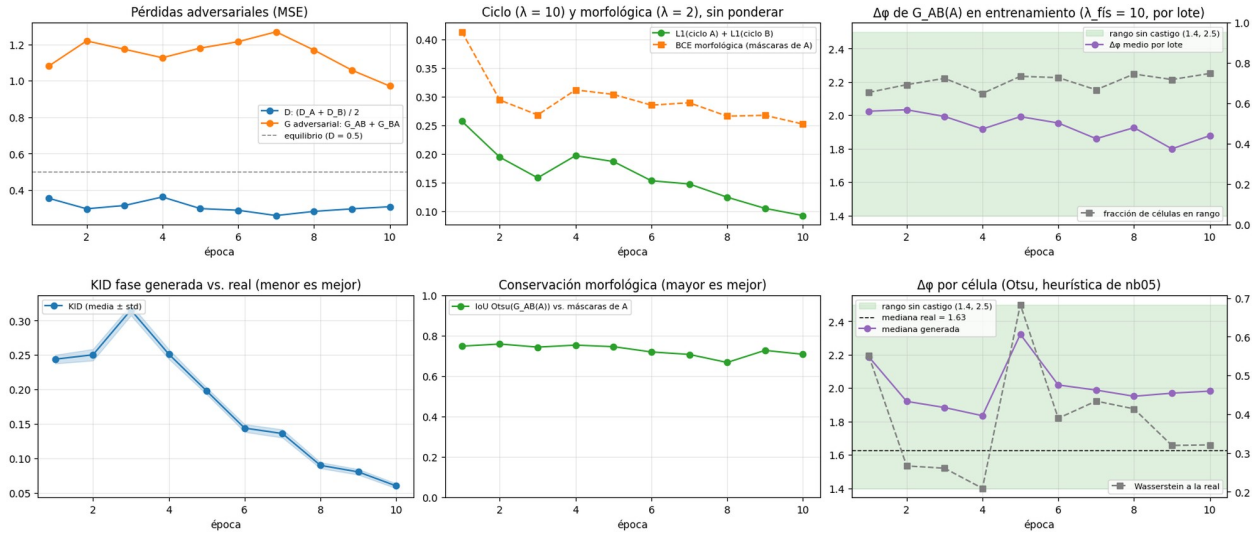


Figura 11. Corrida final. Arriba: pérdidas adversariales, ciclo y morfológica, y $\Delta\varphi$ de entrenamiento. Abajo: KID, IoU y $\Delta\varphi$ de validación por Otsu (mediana generada, W1 y la mediana real de 1.63 rad).

Tabla 3. Métricas finales frente a la referencia real.

Métrica (validación, época 10)	**Fase generada**	**Fase real**	**Lectura**
KID ($\pm$ desv.)	0.060 ± 0.004	—	Desde 0.24 en la época 1; la mejor de 10 épocas es la última
IoU Otsu vs. máscaras de A	0.71	—	Conserva la morfología; ya no es independiente (se optimiza $\mathcal{L}_{\text{morf}}$)
$\Delta\varphi$ mediana (rad)	1.98	1.63	Sesgo de $+0.35$ rad, dentro del rango plausible
$\Delta\varphi$ en $[1.4, 2.5]$	86.4 %	60.5 %	Distribución comprimida hacia el rango: pierde las colas reales
W1 de $\Delta\varphi$ (rad)	0.32	0	Comparable a 3b y 3c (0.33–0.36); 4a tiene 0.12, pero con IoU 0.01
Células interiores evaluadas	2 492	1 419	En 960 imágenes generadas y 442 reales (2.6 y 3.2 por imagen)

- **Sesgo del filtro.** El modelo se entrenó y se evaluó con 3 779 de 10 099 parches, los menos densos y sin células en contacto. No queda evaluado en racimos.
- **Solo células sanas.** Los parches con células infectadas se excluyeron. El modelo no dice nada sobre la fase de un eritrocito parasitado.
- **Variabilidad.** Hay una corrida por configuración y una semilla. La orientación alcanzada sin $\mathcal{L}_{\text{morf}}$ dependió del arranque. No se comparó contra una línea base sin aprendizaje para la traducción (por ejemplo, el campo claro invertido y reescalado).
- **Término físico.** El gradiente de $\max - \min$ llega solo a dos píxeles por célula, y en modo lote quedó casi inerte ($\mathcal{L}_{\Delta\varphi} \approx 0$ en las últimas épocas de la corrida final). La mejora de $\Delta\varphi$ se debe sobre todo a la restricción morfológica.

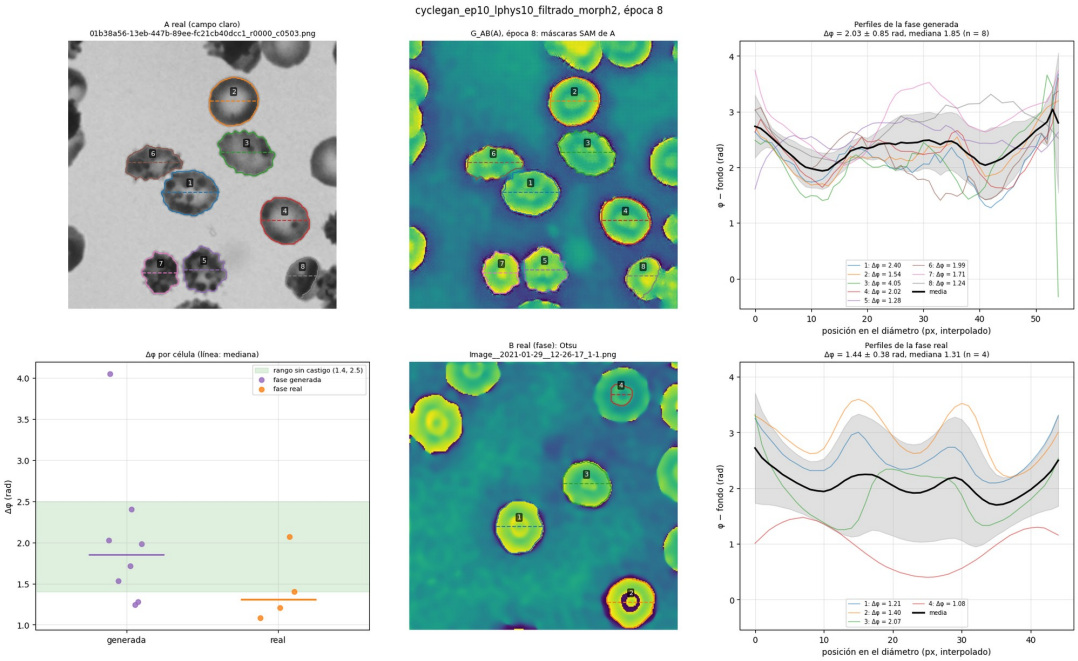


Figura 12. Inspección de perfiles (celda de nb06, época 8 de la corrida final). Arriba: campo claro con las máscaras SAM, fase generada y perfiles por célula ($\Delta\varphi$ 2.03$\pm$0.85 rad, mediana 1.85). Abajo: $\Delta\varphi$ por célula de las fases generada y real, y una fase real con sus perfiles (mediana 1.31). Los perfiles generados muestran bordes altos y un valle central, como los reales, pero más ruidosos.

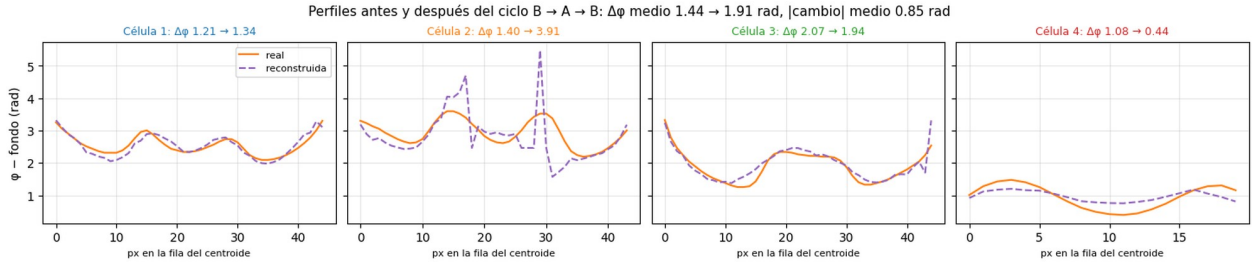


Figura 13. Ciclo $B \to A \to B$ con el checkpoint final: perfiles de una fase real y de su reconstrucción. Las células 1 y 3 se reconstruyen bien. La 2 tiene un pico donde la fase real tiene un hueco envuelto (el $\Delta\varphi$ pasa de 1.40 a 3.91 rad), y la 4, cortada por el recorte, pierde contraste.

8. Conclusiones

(1) Se construyó un pipeline reproducible que armoniza ambos dominios: tamaño de célula igualado por cámara, split sin fuga por imagen u holograma de origen, filtrado de artefactos y máscaras SAM por célula.

(2) Un CycleGAN no pareado aprende a producir texturas de fase realistas, pero sin una restricción espacial no conserva la correspondencia célula a célula: borra o funde racimos, invierte la polaridad o reubica las células, y aun así reconstruye el ciclo. Ni el término físico sobre $\Delta\varphi$, que no ve el signo, ni negar la entrada lo corrigieron.

(3) La pérdida morfológica con las máscaras del campo claro lo resuelve desde la primera época. La solución final (corrida 5 de la tabla 2) obtiene KID 0.060, IoU 0.71, mediana de $\Delta\varphi$ 1.98 rad frente a 1.63 real y perfiles con borde alto y valle central.

(4) La generación de fase plausible a partir de campo claro es viable para eritrocitos sanos y aislados, con la fase en unidades relativas. Mejorarla requiere un término físico sensible al signo y al perfil completo, más épocas y semillas, y una evaluación cuantitativa con radianes absolutos.

Referencias

[1] J.-Y. Zhu, T. Park, P. Isola y A. A. Efros, «Unpaired image-to-image translation using cycle-consistent adversarial networks», en *Proc. IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2223–2232. arXiv:1703.10593.

[2] V. Thapa, A. S. Galande, G. H. P. Ram y R. John, «TIE-GANs: single-shot quantitative phase imaging using transport of intensity equation with integration of GANs», *Journal of Biomedical Optics*, vol. 29, n.º 1, 016010, 2024. doi:10.1117/1.JBO.29.1.016010.

[3] Y. Zhang, M. A. Noack, P. Vagovic, K. Fezzaa, F. Garcia-Moreno, T. Ritschel y P. Villanueva-Perez, «PhaseGAN: a deep-learning phase-retrieval approach for unpaired datasets», *Optics Express*, vol. 29, n.º 13, pp. 19593–19604, 2021. doi:10.1364/OE.423222.

[4] R. Castañeda, C. Trujillo y A. Doblas, «A human erythrocytes hologram dataset for learning-based model training», *Data in Brief*, vol. 54, 110424, 2024. doi:10.1016/j.dib.2024.110424.

[5] «P. Vivax (Malaria) Infected Human Blood Smears», dataset en Kaggle (orvile), `https://www.kaggle.com/datasets/orvile/p-vivax-malaria-infected-human-blood-smears`. Máscaras con Segment Anything (SAM ViT-B, Kirillov et al., 2023).